

UNIVERSIDADE ESTADUAL DO NORTE FLUMINENSE DARCY RIBEIRO
CENTRO DE CIÊNCIA E TECNOLOGIA
LABORATÓRIO DE METEOROLOGIA – LAMET
PROGRAMA DE PÓS-GRADUAÇÃO EM CLIMA E ENERGIA – PPGC&E
DISCIPLINA: GEOMODELAGEM DO POTENCIAL ENERGÉTICO E DO
MICROCLIMA URBANO
PROFESSORA: DRA. RAQUEL JAHARA LOBOSCO

ANA FLÁVIA RODRIGUES BARCELOS CORDEIRO

RAYANE PEREIRA DE SOUZA

RELATÓRIO: GEOMODELAGEM, CLIMA E PRODUÇÃO DE AÇAÍ

Macaé
2026

SUMÁRIO

1. INTRODUÇÃO	3
2. OBJETIVO	4
2.1 Objetivo Geral.....	4
2.2 Objetivos Específicos.....	4
3. FUNDAMENTAÇÃO TEÓRICA.....	5
3.1 O açaizeiro (<i>Euterpe oleracea</i> Mart.): biologia, fenologia e calendário de safra.....	5
3.2 Transmissão oral da doença de Chagas associada ao consumo de açaí.....	5
3.3 Reanálise climática ERA5-Land (Copernicus).....	6
3.4 Visão computacional e a arquitetura YOLO para aplicações agrícolas.....	6
4. METODOLOGIA	7
4.1 Área de estudo.....	7
4.2 Parte 1 – Obtenção e processamento dos dados climáticos	8
4.3 Parte 2 – Visão computacional com YOLO11/Ultralytics	9
4.3.1 Experimento 1 – Detecção de açaí (classe única).....	9
4.3.2 Experimento 2 – Detecção conjunta de açaí e barbeiro	9
4.4 Parte 3 – Análise integrada	10
5. RESULTADO E DISCUSSÃO	10
5.1 Mapeamento climático sazonal da região produtora de açaí	10
5.2 Dataset, anotação e treinamento do modelo de detecção de açaí	16
5.3 Dataset, anotação e treinamento do modelo conjunto açaí + barbeiro	20
5.4 Análise integrada entre clima, produção de açaí e risco fitossanitário	24
6. CONCLUSÕES	27
7. REFERÊNCIAS.....	29

1. INTRODUÇÃO

O monitoramento sistemático de variáveis climáticas e a aplicação de tecnologias emergentes voltadas à segurança alimentar constituem pilares indispensáveis para o desenvolvimento sustentável de cadeias agroindustriais na Região Norte do Brasil. Dentre os produtos de maior relevância socioeconômica e cultural, o fruto do açaí (*Euterpe oleracea* Mart.) destaca-se como base alimentar regional e commodity em expansão global, sendo cultivado predominantemente em áreas de várzea, igapó e, mais recentemente, em terra firme no estuário amazônico (EMBRAPA, [s.d.]; OLIVEIRA; NETO; PENA, 2007).

Todavia, a cadeia produtiva do açaí enfrenta um desafio fitossanitário particular: a transmissão oral da doença de Chagas. Diferentemente da via vetorial clássica (picada do inseto), a contaminação ocorre quando o inseto triatomíneo popularmente conhecido como barbeiro, ou seus dejetos infectados pelo protozoário *Trypanosoma cruzi*, é acidentalmente triturado junto aos frutos durante a colheita ou a etapa artesanal de despulpamento ("batedura") (NÓBREGA et al., 2009). Estudos epidemiológicos recentes reforçam que a transmissão oral já superou a transmissão vetorial clássica como principal via de infecção aguda na Amazônia brasileira, respondendo por cerca de 85% dos casos agudos notificados no país, com forte concentração espacial nos municípios produtores de açaí do Pará (CFF, 2024; PACHECO et al., 2021).

A dinâmica comportamental e os padrões de dispersão do inseto vetor são fortemente condicionados por limiares microclimáticos de temperatura e umidade relativa: os triatomíneos apresentam termopreferência estreita (geralmente entre 24 °C e 30 °C) e alteram seus ecótopos e comportamento de abrigo em resposta a variações sazonais de temperatura e umidade (GUARNERI et al., 2003; GARZA et al., 2020). Modificações ambientais sazonais podem, portanto, alterar os padrões de deslocamento do vetor entre palmeiras silvestres e zonas de processamento de frutos. Diante da semelhança visual entre os pequenos frutos escuros de açaí e o corpo do inseto, os métodos convencionais de triagem puramente visual humana mostram-se vulneráveis à falha, sobretudo em cenários de alta produtividade e baixa iluminação.

Nesse cenário, a integração de técnicas de geomodelagem espacial a algoritmos de visão computacional surge como abordagem científica capaz de subsidiar, ainda que de forma exploratória, estratégias de vigilância. Por um lado, dados meteorológicos de reanálise de alta resolução do modelo ERA5-Land, produzido pelo Copernicus Climate Change Service (C3S) do ECMWF, permitem mapear as janelas sazonais de variabilidade climática no Estado do Pará

(MUÑOZ-SABATER et al., 2021). Por outro, redes neurais convolucionais de última geração, como a arquitetura YOLO11 (You Only Look Once), permitem automatizar a segmentação de instâncias em imagens de campo, oferecendo um mecanismo adicional de triagem visual (ULTRALYTICS, 2024; SAPKOTA; KARKEE, 2024).

Este relatório documenta a execução das três partes da atividade prática proposta na disciplina: (i) o mapeamento sazonal de variáveis meteorológicas (temperatura, precipitação, vento e umidade) para a região do Baixo Tocantins, principal polo produtor de açaí do Pará; (ii) o treinamento de modelos YOLO11 de segmentação para detecção de cachos de açaí e do inseto barbeiro; e (iii) uma discussão integrada, estritamente exploratória, entre os padrões climáticos observados e o calendário de safra do açaizeiro.

2. OBJETIVO

2.1 Objetivo Geral

Desenvolver uma análise geoespacial e computacional integrada da dinâmica climática e da produção de açaí no Estado do Pará, combinando o mapeamento sazonal de variáveis meteorológicas por reanálise Copernicus/ERA5-Land ao treinamento de redes neurais de visão computacional (YOLO11/Ultralytics) para a identificação automatizada de cachos de açaí e do inseto vetor barbeiro.

2.2 Objetivos Específicos

- Construir, com a biblioteca Cartopy, um mapa do Estado do Pará destacando a região produtora de açaí do Baixo Tocantins (Igarapé-Miri, Cametá, Abaetetuba e entorno de Belém);
- Processar dados de reanálise ERA5/ERA5-Land (Copernicus) referentes ao ano de 2024, às 15h (hora local), produzindo mapas sazonais de contorno de temperatura do ar, precipitação, intensidade do vento e umidade relativa para as quatro estações do ano;
- Organizar e anotar, via plataforma Roboflow, um banco de imagens de açaizeiros, cachos e frutos, bem como de exemplares do inseto barbeiro, utilizando máscaras de segmentação poligonal;
- Treinar redes neurais da família YOLO11 (variantes de segmentação yolo11l-seg e yolo11m-seg) para detecção da classe açaí e, em uma segunda etapa, das classes açaí e barbeiro conjuntamente, avaliando as métricas de precisão, recall e mAP;

- Realizar uma discussão exploratória integrando as flutuações sazonais climáticas com o calendário de safra do açaizeiro e com os resultados da visão computacional, sem estabelecer relações causais não sustentadas por dados de campo.

3. FUNDAMENTAÇÃO TEÓRICA

3.1 O açaizeiro (*Euterpe oleracea* Mart.): biologia, fenologia e calendário de safra

O açaizeiro é uma palmeira nativa da Amazônia, da família Arecaceae, que forma touceiras multicaules e ocorre naturalmente em áreas de várzea e igapó, sendo também cultivada em terra firme (EMBRAPA, [s.d.]). A espécie desenvolve-se de forma ótima sob precipitação anual superior a 2.000 mm, umidade relativa média acima de 80% e temperatura média em torno de 28 °C, condições típicas do estuário amazônico paraense (OLIVEIRA; NETO; PENA, 2007).

Estudos fenológicos conduzidos pela Embrapa Amazônia Oriental mostram que a emissão de espatas e a floração do açaizeiro concentram-se no período de maior incidência de chuvas, enquanto a frutificação e a colheita ocorrem cerca de seis meses depois, tipicamente no período de menor precipitação (EMBRAPA, [s.d.]). Esse deslocamento temporal entre o pico de chuvas (floração) e o pico de colheita (estiagem) é a base fisiológica para a definição de duas épocas de frutificação na literatura agrônômica: uma "safra" concentrada no segundo semestre do ano (associada à estiagem) e uma "entressafra" no primeiro semestre, associada ao período mais chuvoso. Cultivares mais recentes, como a BRS Pai d'Égua, foram desenvolvidas justamente para reduzir essa sazonalidade, produzindo 46% da colheita na entressafra (janeiro a junho) e 54% na safra (julho a dezembro) (EMBRAPA, 2019).

3.2 Transmissão oral da doença de Chagas associada ao consumo de açaí

A doença de Chagas, causada pelo protozoário *Trypanosoma cruzi*, é classicamente transmitida por triatomíneos hematófagos ("barbeiros"). Contudo, na Região Amazônica, a via de infecção predominante nas últimas duas décadas passou a ser a transmissão oral, decorrente da contaminação de alimentos, sobretudo o açaí, pelo esmagamento acidental do inseto ou de suas fezes durante o processamento artesanal do fruto (NÓBREGA et al., 2009; PACHECO et al., 2021). Levantamentos epidemiológicos recentes indicam que a transmissão oral responde por cerca de 85% dos casos agudos de doença de Chagas notificados no Brasil, com concentração expressiva na Região Norte (CFF, 2024).

Do ponto de vista ecológico, o comportamento e a distribuição dos triatomíneos são fortemente moldados pela temperatura e pela umidade relativa do ar. Espécies como *Rhodnius prolixus* e *Triatoma infestans* apresentam termopreferência relativamente estreita, em geral entre 24 °C e 30 °C, com efeitos mensuráveis sobre taxas metabólicas, oviposição e comportamento de abrigo (GUARNERI et al., 2003; LORENZO; LAZZARI, 1998 apud GARZA et al., 2020). Modelos de adequabilidade climática em escala global reforçam que a temperatura mínima do mês mais frio e a umidade relativa estão entre as variáveis mais explicativas da distribuição de triatomíneos (GARZA et al., 2020). Essas evidências sustentam, em caráter hipotético, a investigação de possíveis relações entre a sazonalidade climática do Baixo Tocantins e o risco de contato entre o vetor e a cadeia produtiva de açaí, relação que, no presente trabalho, é tratada como hipótese a ser aprofundada com dados de campo, e não como conclusão.

3.3 Reanálise climática ERA5-Land (Copernicus)

O ERA5-Land é um produto operacional de reanálise da componente terrestre da quinta geração de reanálise europeia (ERA5), desenvolvido pelo European Centre for Medium-Range Weather Forecasts (ECMWF) no âmbito do Copernicus Climate Change Service (C3S). O produto cobre o período de 1950 até o presente, em resolução horária e espacial de aproximadamente 9 km, obtida por meio da integração do modelo de superfície terrestre do ECMWF (CHTESSEL) forçado por dados atmosféricos de baixo nível do ERA5, com correção de elevação para o estado termodinâmico próximo à superfície (MUÑOZ-SABATER et al., 2021). Por oferecer cobertura espacial contínua mesmo em regiões com escassez de estações meteorológicas de superfície, como é o caso do interior do estuário amazônico, o ERA5-Land constitui uma fonte de dados adequada para a caracterização climática sazonal da região produtora de açaí do Baixo Tocantins.

3.4 Visão computacional e a arquitetura YOLO para aplicações agrícolas

A família de redes neurais YOLO (You Only Look Once), originalmente proposta por Redmon et al. (2016), consolidou-se como uma das arquiteturas mais utilizadas em tarefas de detecção e segmentação de instâncias em tempo real, por unificar em uma única passagem da rede as etapas de localização e classificação de objetos. A versão YOLO11, lançada pela Ultralytics em 2024, introduziu otimizações de backbone e de cabeça de segmentação que melhoram a relação entre acurácia e custo computacional em relação às versões anteriores (ULTRALYTICS, 2024).


Estudos recentes de comparação entre YOLO11 e YOLOv8 aplicados à segmentação de instâncias de frutos em ambientes de pomar mostram que as variantes intermediárias ("m") e grandes ("l") da família YOLO11 tendem a apresentar os melhores valores de mAP50 tanto para caixas delimitadoras quanto para máscaras de segmentação, ao custo de um tempo de inferência ligeiramente maior do que as variantes mais leves ("n") (SAPKOTA; KARKEE, 2024). Esses achados foram utilizados para justificar, no presente trabalho, a escolha das variantes yolol1l-seg e yolol1m-seg como ponto de partida para o treinamento das redes de detecção de açaí e de barbeiro, respectivamente, buscando equilíbrio entre capacidade de representação de texturas complexas (aglomerados de frutos, insetos em fundos poluídos) e o tempo de treinamento disponível em ambiente de GPU gratuita (Google Colab, NVIDIA T4).

4. METODOLOGIA

4.1 Área de estudo

Como etapa preliminar ao processamento climatológico e computacional, realizou-se a delimitação cartográfica e a caracterização espacial do recorte territorial de interesse. A estruturação geográfica da área de estudo, com foco na distribuição político-administrativa do Estado do Pará e o isolamento estratégico da microrregião produtora do Baixo Tocantins (abrangendo os principais polos agrícolas ribeirinhos como Igarapé-Miri, Cametá e Abaetetuba), está representada na Figura 1. A partir desta contextualização espacial, tornam-se inteligíveis as respostas micrometeorológicas avaliadas nas seções subsequentes.

Figura 1 – Estado do Pará com destaque (retângulo vermelho) para a região produtora de açaí do Baixo Tocantins (Igarapé-Miri, Cametá, Abaetetuba e entorno de Belém).



Fonte: Autoria própria (2026), gerado com a biblioteca Cartopy no ambiente Google Colab.

4.2 Parte 1 – Obtenção e processamento dos dados climáticos

O pipeline de geoprocessamento foi desenvolvido em linguagem Python, no ambiente Google Colab. Os dados meteorológicos foram obtidos junto ao Copernicus Climate Data Store (CDS), por meio da API cdsapi, a partir dos produtos reanalysis-era5-land (dados horários de temperatura do ar a 2 m, temperatura do ponto de orvalho a 2 m e componentes horizontais do vento a 10 m) e reanalysis-era5-land-monthly-means (médias mensais de precipitação total). Os dados referem-se ao ano de 2024, extraídos para o horário de 18h UTC, correspondente às 15h em horário local de Belém (UTC–3), conforme especificado na atividade.

As variáveis foram agrupadas em quatro estações do ano segundo a convenção astronômica do Hemisfério Sul: Verão (dezembro–fevereiro), Outono (março–maio), Inverno (junho–agosto) e Primavera (setembro–novembro), com as médias espaciais calculadas por

estação por meio da biblioteca xarray. A temperatura do ar, originalmente em Kelvin, foi convertida para graus Celsius pela relação $T(^{\circ}\text{C}) = T(\text{K}) - 273,15$. A intensidade do vento foi calculada a partir das componentes horizontais u e v pela relação:

$$V = \sqrt{u^2 + v^2}$$

A composição cartográfica final foi renderizada com a biblioteca Cartopy, produzindo grades de contorno (contourf) em projeção PlateCarree para cada uma das quatro variáveis (temperatura, precipitação, vento e umidade relativa), nas quatro estações do ano, totalizando 16 mapas climáticos sazonais, conforme solicitado na atividade. Complementarmente, foi elaborado um mapa de apoio de uso e cobertura do solo (MapBiomas, via Google Earth Engine) sobreposto a um índice de probabilidade de ocorrência de açais na região de estudo.

4.3 Parte 2 – Visão computacional com YOLO11/Ultralytics

A consolidação e a anotação do banco de imagens foram realizadas na plataforma Roboflow, adotando a técnica de segmentação de instâncias (máscaras poligonais), em vez de caixas delimitadoras simples, de modo a acomodar a alta densidade e a sobreposição de frutos nos cachos de açaí. Duas versões do dataset foram construídas e utilizadas em dois experimentos de treinamento sucessivos, descritos a seguir.

4.3.1 Experimento 1 – Detecção de açaí (classe única)

No primeiro experimento, foi utilizada a versão 1 do dataset (workspace "acai-v4l4k" no Roboflow), contendo exclusivamente a classe açaí (identificada na exportação como classe "0"). O modelo yolo11l-seg.pt (variante "large" de segmentação) foi treinado por 5 épocas, com imagens redimensionadas para 640×640 pixels e batch size de 16, em GPU NVIDIA T4 (Google Colab).

4.3.2 Experimento 2 – Detecção conjunta de açaí e barbeiro

No segundo experimento, a versão 2 do dataset foi expandida para incluir também a classe barbeiro, composta por imagens do inseto triatomíneo em diferentes contextos (sobre a pele humana, sobre cachos de açaí, sobre superfícies diversas). Optou-se pelo modelo yolo11m-seg.pt (variante "medium"), por apresentar, segundo a literatura consultada, uma das melhores relações entre acurácia de segmentação e estabilidade de treinamento (SAPKOTA; KARKEE, 2024). O treinamento foi parametrizado para 100 épocas, resolução de 640×640 pixels, batch size 16 e critério de parada antecipada (patience) de 15 épocas sem melhora da métrica de validação.

Para mitigar falsos positivos cruzados decorrentes da semelhança cromática (tons arroxeados/escuros) e geométrica (formas ovaladas/arredondadas) entre o fruto e o inseto, dois ajustes de hiperparâmetros foram aplicados: (i) $cls = 3,0$, triplicando o peso da função de perda de classificação, de modo a penalizar mais fortemente confusões de identidade entre as classes; e (ii) manutenção do parâmetro box em 7,5 (padrão), preservando a sensibilidade de localização espacial das máscaras.

4.4 Parte 3 – Análise integrada


Na etapa final, os resultados climáticos sazonais (Parte 1) foram cruzados com o calendário de safra do açaizeiro documentado pela Embrapa Amazônia Oriental (floração no período chuvoso, colheita cerca de seis meses depois, no período de estiagem), construindo-se um índice qualitativo de produção ("Muito Baixo", "Baixo", "Médio", "Alto") por estação do ano. É importante destacar que esse índice não deriva de contagem de imagens datadas por estação, o dataset de visão computacional não possui metadados temporais equivalentes, mas do calendário fenológico oficial da cultura, mapeado sobre as quatro estações meteorológicas utilizadas na Parte 1. A discussão resultante é, portanto, deliberadamente exploratória, sem inferência de causalidade estatística entre clima, produção e presença do vetor.

5. RESULTADO E DISCUSSÃO

5.1 Mapeamento climático sazonal da região produtora de açaí

Para contextualizar a dinâmica ambiental do Baixo Tocantins, área que engloba municípios polo na produção como Igarapé-Miri, Cametá e Abaetetuba, realizou-se o processamento dos dados meteorológicos horários oriundos da base de dados globais Copernicus (ERA5-Land) para o ano de 2024. Os dados foram filtrados especificamente para o horário local de 15h, momento em que as taxas de irradiância e as interações térmicas na camada limite planetária são mais acentuadas. Como primeira etapa para a compreensão desse cenário regional, a circulação e a força dos ventos foram espacializadas através de mapas sazonais de contorno, conforme apresentados na figura 2.


Figura 2 – Mapas de contorno da intensidade sazonal do vento (m/s) na região do Baixo Tocantins às 15h (horário local) no ano de 2024.



Fonte: Autoria própria (2026), com dados do satélite Copernicus (ERA5-Land).

A análise da Figura 2 indica que a intensidade do vento apresenta variações sazonais sutis na área de estudo, atuando como um regulador das taxas de evapotranspiração na região produtora. Na sequência da análise ambiental, sabendo que a umidade atmosférica interage com esses fluxos de vento e regula o estresse hídrico das palmeiras de açaí, processou-se o comportamento sazonal da umidade relativa do ar, que é detalhado na Figura 3.


Figura 3 – Mapas de contorno da umidade relativa do ar (%) sazonal na região do Baixo Tocantins às 15h (horário local) no ano de 2024.



Fonte: Autoria própria (2026), com dados do satélite Copernicus (ERA5-Land).

Os padrões térmicos locais tendem a alinhar-se intimamente com os regimes de umidade observados na Figura 3, demonstrando que os períodos com menores índices de umidade relativa coincidem com as épocas de elevação da temperatura do ar. Para evidenciar geograficamente essas oscilações de calor e identificar os picos de temperatura nos diferentes trimestres do ano, gerou-se o mapeamento térmico que se observa na figura 4.


Figura 4 – Mapas de contorno da temperatura do ar (°C) sazonal na região do Baixo Tocantins às 15h (horário local) no ano de 2024.



Fonte: Autoria própria (2026), com dados do satélite Copernicus (ERA5-Land).

Embora as temperaturas ilustradas na Figura 4 permaneçam dentro de uma faixa ideal e estável para o desenvolvimento adaptativo do açaizeiro ao longo do ano, a sustentabilidade ecológica da produção depende fortemente do balanço hídrico. Como a chuva é o principal motor de reposição de água no solo e o estado do Pará possui regimes pluviométricos bem-marcados, conforme mostrados na Figura 5, os índices de precipitação total acumulada foram calculados sazonalmente.

Figura 5 – Mapas de contorno da precipitação total acumulada (mm/dia) sazonal na região do Baixo Tocantins às 15h (horário local) no ano de 2024.



Fonte: Autoria própria (2026), com dados do satélite Copernicus (ERA5-Land).


As médias espaciais extraídas para a área de estudo (Tabela 1, apresentada na Seção 5.4) confirmam o padrão qualitativo visível nos mapas: o Outono concentra a maior precipitação média (12,25 mm/dia) e a maior umidade relativa (76,66%), com temperatura mais amena (29,29 °C), período de maior nebulosidade associada à Zona de Convergência Intertropical (ZCIT) e à estação chuvosa amazônica. A Primavera, por sua vez, é a estação mais seca (0,32 mm/dia), mais quente (35,11 °C) e menos úmida (39,63%), refletindo a maior incidência de radiação solar direta sob céu mais limpo, e não uma estação fria como sugeriria o nome em latitudes temperadas.

É fundamental destacar, como já apontado na atividade, que a nomenclatura "Verão/Outono/Inverno/Primavera" segue estritamente a convenção astronômica do Hemisfério Sul (respectivamente dez–fev, mar–mai, jun–ago, set–nov) e não a divisão popular amazônica em "período chuvoso"/"período seco" (muitas vezes chamados localmente de "inverno" e "verão", em sentido invertido ao meteorológico). Por se situar muito próxima da

linha do Equador (entre 1,4° S e 2,6° S), a região do Baixo Tocantins não apresenta estações térmicas marcadas pela inclinação solar, como ocorre em latitudes médias; quem comanda a variabilidade sazonal ali é o regime de nebulosidade e precipitação associado à migração da ZCIT, e não o ângulo de incidência solar. A intensidade do vento acompanha esse mesmo padrão de forma mais discreta, com valores médios mais baixos no Outono (mais chuvoso e nublado, $\approx 1,3$ m/s) e mais altos na Primavera (mais seca, $\approx 2,4$ m/s), coerente com a maior mistura vertical da camada limite em condições de céu claro.

A expressiva variação nos índices pluviométricos sazonais apresentada na Figura 5 consolida o entendimento de que a disponibilidade hídrica é altamente variável ao longo dos trimestres. A fim de verificar como essa dinâmica macroclimática interage com o uso da terra e mapear as áreas onde as palmeiras de fato encontram condições ideais de estabelecimento, realizou-se o cruzamento dos dados do MapBiomas com a aptidão da espécie, conforme ilustrado na Figura 6, o mapa integrado a seguir.

Figura 6 – Mapeamento do uso e cobertura da terra (MapBiomas) integrado ao índice de probabilidade de ocorrência de espécimes de açai na área de estudo.



Fonte: Autoria própria (2026), adaptado de dados públicos do MapBiomas.


A integração cartográfica exibida na Figura 6 corrobora o forte vínculo entre os parâmetros climáticos monitorados e as áreas geográficas de adensamento das palmeiras, validando espacialmente as zonas prioritárias para a coleta de dados e modelagem computacional.

5.2 Dataset, anotação e treinamento do modelo de detecção de açaí

O primeiro experimento de visão computacional teve como objetivo detectar cachos, frutos e áreas de produção de açaí (classe única) a partir de imagens de campo e de fontes complementares organizadas no Roboflow. As Figuras 7 e 8 ilustram, respectivamente, um mosaico de imagens de treino com as máscaras de segmentação sobrepostas e um mosaico de imagens de validação com as máscaras de referência (ground truth).

Superada a etapa de modelagem macroclimática, o trabalho avançou para o desenvolvimento de soluções baseadas em inteligência artificial e visão computacional. O primeiro experimento focou na identificação automatizada e isolada de cachos de açaí por meio da arquitetura de redes neurais YOLO11-seg, configurada sob uma abordagem de classe única para segmentação de instâncias e submetida a um treinamento de 5 épocas. Para instruir o algoritmo a reconhecer os padrões visuais do fruto, foi estruturado um conjunto de dados robusto contendo imagens de campo. O mosaico estrutural contendo os lotes de imagens selecionadas para o treinamento, devidamente anotadas com as etiquetas de identificação onde o açaí foi localizado, é apresentado a seguir.

Figura 7 – Mosaico de amostras do conjunto de treinamento evidenciando a identificação e anotação poligonal das instâncias da classe açaí.



Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

O rigor geométrico exposto no mosaico de treinamento da Figura 7 forneceu subsídios para que o algoritmo extraísse características texturais e cromáticas robustas dos frutos em ambiente real. De modo a validar o desempenho prático da rede diante de cenários inéditos e avaliar a capacidade do modelo de realizar inferências automáticas em condições de campo, o algoritmo foi submetido ao lote de testes independentes. O mosaico contendo os resultados visuais gerados nessa etapa de validação, exibindo as predições automáticas onde o açaí foi identificado com sucesso pelo modelo treinado, é apresentado abaixo na Figura 8.


Figura 8 – Mosaico de validação de instâncias de cachos de açaí obtidos pelo modelo YOLO11l-seg



Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

Para além da visão de conjunto oferecida pelo mosaico de validação, é ilustrativo observar o comportamento do modelo em um exemplo individual de inferência. A Figura 9 apresenta uma predição isolada sobre um cacho de açaí em ambiente de campo, evidenciando as caixas delimitadoras (bounding boxes) e os respectivos escores de confiança (confidence score) atribuídos pelo algoritmo a cada instância detectada.

Figura 9 – Exemplo do resultado de predição individual do modelo YOLO11-seg sobre um cacho de açaí, evidenciando as caixas delimitadoras e os escores de confiança (confidence score) atribuídos a cada instância detectada.




Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

Nesse exemplo, o modelo identificou corretamente as duas principais regiões de concentração de frutos do cacho, atribuindo escores de confiança de 0,72 e 0,65, respectivamente, o que indica um bom nível de certeza da rede mesmo diante de sobreposição parcial entre as instâncias e de variações de iluminação e fundo vegetativo.

As inferências demonstradas no mosaico da Figura 8 comprovam que o modelo de classe única obteve sucesso na delimitação dos frutos, demonstrando alta assertividade mesmo em ambientes de iluminação natural variável e sombreamento foliar. De forma a consolidar numericamente os resultados observados visualmente e analisar estatisticamente o aprendizado do algoritmo ao longo das épocas, gerou-se o histórico matemático do treino. O comportamento das funções de custo (caixas e máscaras) e a evolução dos índices de precisão geral calculados no decorrer do processo são detalhados no gráfico da figura 10.

Figura 10 – Curvas de convergência da função de perda (loss) e métricas de desempenho (mAP50 e mAP50-95) obtidas no experimento de classe única.



Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.


Como se pode notar nos gráficos da Figura 10, as curvas de perda (loss) decresceram de forma acentuada tanto para o conjunto de treino quanto de validação, enquanto os índices de precisão média (mAP50 e mAP50-95) demonstraram uma rápida inclinação ascendente, aproximando-se da estabilidade nas épocas finais. Esse comportamento indica uma convergência ágil e satisfatória, comprovando a eficácia e robustez da variante 'Large' da arquitetura YOLO11 para este tipo de alvo agrícola. Estes resultados excelentes fornecem bases sólidas para a evolução do projeto em direção à abordagem multiclasse com vetores biológicos apresentada na seção subsequente

5.3 Dataset, anotação e treinamento do modelo conjunto açaí + barbeiro

Visando mitigar os riscos fitossanitários e de saúde pública associados à transmissão oral da doença de Chagas por meio da contaminação acidental do fruto durante o despulpamento, o segundo experimento expandiu o escopo de análise computacional. Desenvolveu-se um modelo multiclasse baseado na arquitetura YOLO11m-seg ('Medium') para a detecção simultânea do fruto e do seu inseto vetor (barbeiro). Os gráficos com o histórico do comportamento das perdas e o ganho de acurácia calculados para este novo cenário conjunto de detecção são introduzidos no gráfico abaixo.

Para instruir adequadamente o modelo a diferenciar os contornos do triatomíneo das superfícies complexas dos cachos, foi gerado um dataset enriquecido. O mosaico contendo o lote de imagens estruturadas e devidamente rotuladas com as marcações de polígonos que serviram de base para o treinamento multiclasse é introduzido na Figura 11 abaixo.

Figura 11 – Mosaico estrutural de amostras do conjunto de treinamento multiclasse evidenciando as anotações para as classes açaí e barbeiro.



Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

As diretrizes estritas de rotulagem evidenciadas na Figura 11 serviram como base essencial para instruir a rede. A fim de validar a capacidade prática do modelo segmentar de forma autônoma e simultânea tanto o vetor biológico quanto o produto agrícola em condições reais de campo, o algoritmo gerou as suas predições sobre o banco de dados de teste. O mosaico contendo os resultados visuais automáticos obtidos na etapa de aferição pode ser verificado na Figura 12.


Figura 12 – Mosaico de validação exibindo as inferências automáticas e máscaras de segmentação finais para as classes açai e barbeiro.



Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

De modo complementar à visão de conjunto do mosaico de validação, é ilustrativo observar o comportamento do modelo em um exemplo individual de inferência multiclasse. A Figura 13 apresenta uma predição isolada em que o algoritmo detecta, simultaneamente, uma região de cacho de açai e um exemplar do inseto barbeiro sobre os frutos, evidenciando as caixas delimitadoras e os respectivos escores de confiança atribuídos pelo modelo a cada classe.

Figura 13 – Exemplo de predição individual do modelo YOLO11m-seg evidenciando a detecção simultânea das classes açai e barbeiro, com os respectivos escores de confiança.




Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

Nesse exemplo, o modelo atribuiu um escore de confiança de 0,68 à detecção do barbeiro sobre a superfície do cacho, valor consideravelmente superior ao obtido para a classe açai na mesma região (0,19), o que sugere que a rede identificou com maior segurança o padrão morfológico do inseto do que a delimitação da caixa correspondente ao fruto sobreposto. Esse resultado ilustra, em nível individual, a assimetria de desempenho entre as duas classes já discutida qualitativamente a partir do mosaico de validação, provavelmente associada à menor quantidade de amostras anotadas da classe barbeiro.

Os resultados visuais da Figura 12 atestam a capacidade do algoritmo de localizar o vetor mesmo em ambientes de alta densidade foliar. Para validar quantitativamente as taxas de assertividade desta abordagem multiclasse e analisar o comportamento de convergência do modelo médio, computou-se o histórico das épocas. Os gráficos contendo o comportamento das perdas e o ganho das métricas de acurácia gerados para este cenário conjunto encerram as análises técnicas na figura abaixo.

Figura 14 – Curvas de métricas e perdas (loss) computadas durante o treinamento multiclasse do modelo YOLO11m-seg.



Fonte: Autoria própria (2026), gerado via framework *Ultralytics YOLO11* no ambiente Google Colab.

Como reflexo direto dessa instabilidade, as métricas de precisão, recall e mAP para a classe minoritária oscilam fortemente entre épocas consecutivas (por exemplo, *metrics/precision(B)* alterna entre valores próximos de 0 e de 1,0), em vez de convergir suavemente como no primeiro experimento. Ainda assim, qualitativamente, as inferências de exemplo (Figuras 11 e 12) mostram que o modelo foi capaz de localizar corretamente tanto os cachos de açaí quanto exemplares do inseto barbeiro em contextos visuais distintos (mão humana, folhas, madeira, cachos de frutos), o que indica que, apesar do sobreajuste evidenciado pelas curvas de validação, o modelo aprendeu características discriminativas úteis, resultado esperado em um experimento acadêmico com dataset reduzido e poucas dezenas de imagens da classe barbeiro.

Em termos comparativos, o primeiro experimento (classe única, 5 épocas, yolo11l-seg) apresentou convergência mais estável e métricas de validação mais consistentes do que o segundo experimento (duas classes, 100 épocas programadas/16 efetivas, yolo11m-seg). Isso sugere que a introdução de uma segunda classe visualmente semelhante à primeira (barbeiro versus açaí, ambos escuros e arredondados) e com poucas amostras aumentou substancialmente a dificuldade do problema de aprendizado, mesmo com o ajuste do hiperparâmetro *cls*. Para trabalhos futuros, recomenda-se ampliar o número de imagens anotadas da classe barbeiro, aplicar técnicas de balanceamento de classes (oversampling ou pesos de perda por classe) e considerar validação cruzada, de modo a obter uma estimativa mais confiável do desempenho de generalização do modelo conjunto.

5.4 Análise integrada entre clima, produção de açaí e risco fitossanitário

A Tabela 1 sintetiza as médias sazonais das quatro variáveis climáticas processadas na Parte 1, extraídas para a área de estudo, e o índice qualitativo de produção de açaí atribuído a

cada estação com base no calendário fenológico da Embrapa Amazônia Oriental (floração no período chuvoso; colheita cerca de seis meses depois, no período de estiagem). Cabe destacar que esse índice é qualitativo e sazonal, e não uma medida direta de volume: as bases oficiais de produção agrícola não discriminam a produção de açaí por estação do ano ou por mês, apenas totais anuais. Como referência de escala real, o Pará respondeu por cerca de 89,5% da produção nacional de açaí em 2024, equivalente a aproximadamente 1,7 milhão de toneladas do fruto, sendo o município de Igarapé-Miri, um dos três polos da área de estudo, o maior produtor nacional isolado, com 21,7% desse total (FAPESPA, 2024; IBGE, [s.d.]).


Tabela 1 – Médias sazonais das variáveis climáticas (ERA5-Land, 2024, 15h local) na região do Baixo Tocantins e índice qualitativo de produção de açaí baseado no calendário de safra da Embrapa

Estação	Precipitação (mm/dia)	Temperatura (°C)	Umidade (%)	Vento (m/s)	Índice de produção
Verão	4,48	30,06	68,22	2,03	Baixo
Outono	12,25	29,29	76,66	1,34	Muito Baixo
Inverno	1,31	32,54	50,11	2,00	Médio
Primavera	0,32	35,11	39,63	2,38	Alto

Fonte: Autoria própria (2026), com dados de reanálise climática *ERA5-Land* (Copernicus Climate Data Store) e calendário de safra da Embrapa Amazônia Oriental.

Esses valores são representados graficamente na Figura 15, que ilustra a evolução conjunta das quatro variáveis climáticas sazonais e do índice qualitativo de produção de açaí ao longo do ano, facilitando a visualização integrada dos padrões discutidos a seguir.

Figura 15 – Padrão sazonal integrado entre as variáveis climáticas (precipitação, temperatura, umidade relativa e vento) e o índice qualitativo de produção de açaí, com base nos dados sintetizados na Tabela 1.



Fonte: Autoria própria (2026), elaborado com a biblioteca *matplotlib* (Python), a partir dos dados climáticos ERA5-Land (Copernicus) e do calendário de safra da Embrapa Amazônia Oriental.

O padrão observado é coerente com o calendário de safra do açaizeiro: o Inverno e, sobretudo, a Primavera, estações mais secas, mais quentes e menos úmidas, recebem índice de produção "Médio" e "Alto", pois correspondem, no calendário fenológico, ao período de colheita decorrente da floração ocorrida seis meses antes, no Outono e no início do Inverno (período mais chuvoso). Já o Outono, com a maior precipitação e umidade do ano, concentra o período de floração e de menor disponibilidade de frutos maduros, recebendo o índice "Muito Baixo".

Quanto ao inseto barbeiro, a literatura consultada indica que sua atividade e seus padrões de abrigo respondem a limiares de temperatura e umidade relativamente estreitos (GUARNERI et al., 2003; GARZA et al., 2020). É plausível, em tese, que a estação de colheita (mais seca e quente) coincida com maior movimentação do vetor em busca de abrigo ou de hospedeiros, potencialmente aumentando a probabilidade de contato acidental durante a colheita e o processamento do fruto. Essa hipótese encontra respaldo em evidências empíricas de vigilância entomológica na transição Amazônia-Cerrado, no vizinho estado do Tocantins: um levantamento de longo prazo com cerca de 12 mil triatomíneos silvestres (gêneros

Rhodnius e Panstrongylus) mostrou que a invasão domiciliar por esses vetores foi significativamente maior nos municípios e períodos mais secos, com a dispersão de exemplares em busca de abrigo e luz artificial concentrando-se predominantemente na estação seca, em oposição aos meses mais chuvosos (BRITO et al., 2017). Caso um padrão sazonal semelhante se aplique ao Baixo Tocantins paraense, a maior movimentação do vetor durante a estiagem coincidiria justamente com o período de pico de colheita do açaí (Inverno e, sobretudo, Primavera, conforme a Tabela 1), o que reforça, ainda que em caráter hipotético, o interesse em investigações de campo direcionadas a essa janela sazonal específica. Entretanto, esta permanece uma hipótese e não uma conclusão: o presente trabalho não dispõe de dados de campo (armadilhas entomológicas datadas, coleta sistemática de espécimes por estação) que permitam testar estatisticamente essa relação. A detecção do barbeiro pelo modelo de visão computacional treinado neste trabalho (Seção 5.3) demonstra viabilidade técnica de triagem automatizada, mas as imagens do dataset não possuem metadados de data/estação do ano que permitiriam vinculá-las diretamente aos resultados climáticos da Parte 1.

Reforça-se, portanto, o caráter exploratório desta análise integrada, tal como orientado no enunciado da atividade: a correlação aqui discutida entre variáveis climáticas, calendário de produção e risco de exposição ao vetor reflete padrões fenológicos e ecológicos já documentados na literatura, e não uma relação causal derivada estatisticamente dos dados coletados neste trabalho específico. Investigações futuras que combinem coleta entomológica georreferenciada e datada, dados de produção por talhão e as mesmas variáveis de reanálise climática aqui processadas seriam necessárias para avançar de uma associação plausível para uma inferência causal robusta.

6. CONCLUSÕES

O presente trabalho integrou, de forma didática, três frentes metodológicas distintas, geoprocessamento de dados de reanálise climática, visão computacional por redes neurais profundas e análise exploratória de calendário agrícola, aplicadas à cadeia produtiva do açaí no Baixo Tocantins, Pará.

O mapeamento climático sazonal, obtido a partir do ERA5-Land para o ano de 2024, evidenciou um padrão sazonal marcado e fisicamente consistente: o Outono concentrou a maior precipitação (12,25 mm/dia) e umidade relativa (76,66%), com temperaturas mais amenas (29,29 °C), enquanto a Primavera se destacou como a estação mais seca (0,32 mm/dia), mais quente (35,11 °C) e menos úmida (39,63%). Esse padrão está associado à migração sazonal da

Zona de Convergência Intertropical, e não a uma inclinação solar marcada, dada a proximidade da região com a linha do Equador.

Na frente de visão computacional, o primeiro experimento (classe única, açai, yolo11l-seg, 5 épocas) mostrou convergência estável e métricas de validação consistentes, ainda que limitadas pelo pequeno número de épocas. Já o segundo experimento (classes açai e barbeiro, yolo11m-seg, até 100 épocas com parada antecipada em ≈ 16) revelou sinais claros de sobreajuste, com divergência acentuada entre as perdas de treino e de validação a partir da 13ª época, provavelmente decorrente do desbalanceamento entre classes e do tamanho reduzido do conjunto de validação. Ainda assim, o modelo demonstrou capacidade qualitativa de localizar corretamente tanto cachos de açai quanto exemplares do barbeiro em diferentes contextos visuais, validando a viabilidade técnica da abordagem para triagem automatizada, com necessidade de ampliação do dataset e de técnicas de balanceamento de classes em trabalhos futuros.

A análise integrada entre clima e produção, embora estritamente exploratória, mostrou coerência entre a sazonalidade climática observada e o calendário fenológico do açaizeiro documentado pela literatura agrônômica, com os períodos mais secos e quentes (Inverno/Primavera) coincidindo com o pico de colheita. A eventual relação entre esses mesmos períodos e um maior risco de exposição ao inseto vetor da doença de Chagas permanece como hipótese relevante para a saúde pública regional, cuja confirmação demandaria a integração de dados de campo entomológicos e epidemiológicos georreferenciados, não disponíveis no escopo desta atividade, às ferramentas de geomodelagem e visão computacional aqui demonstradas.

Conclui-se que a combinação de reanálise climática de alta resolução com redes neurais de segmentação de instâncias constitui uma abordagem promissora e replicável para o monitoramento ambiental e fitossanitário de cadeias agroindustriais amazônicas, desde que acompanhada de datasets mais robustos e de validação de campo em trabalhos subsequentes.

7. REFERÊNCIAS

BRITO, R. N.; GORLA, D. E.; DIOTAIUTI, L.; GOMES, A. C. F.; SOUZA, R. C. M.; ABAD-FRANCH, F. Drivers of house invasion by sylvatic Chagas disease vectors in the Amazon-Cerrado transition: a multi-year, state-wide assessment of municipality-aggregated surveillance data. *PLOS Neglected Tropical Diseases*, v. 11, n. 11, e0006035, 2017. DOI: 10.1371/journal.pntd.0006035. Disponível em: <https://journals.plos.org/plosntds/article?id=10.1371/journal.pntd.0006035>. Acesso em: 07 jul. 2026.

CFF – CONSELHO FEDERAL DE FARMÁCIA. Farmacêuticos analisam epidemiologia da doença de Chagas aguda no Brasil. 2024. Disponível em: <https://site.cff.org.br/noticia/noticias-do-cff/10/10/2024/farmaceuticos-analisam-epidemiologia-da-doenca-de-chagas-aguda-no-brasil>. Acesso em: 06 jul. 2026.

EMBRAPA. Açaizeiro (*Euterpe oleracea* Mart.). Brasília, DF: Embrapa, [s.d.]. Disponível em: <https://www.embrapa.br/busca-de-publicacoes/-/publicacao/395193/acaizeiro-euterpe-oleracea-mart>. Acesso em: 06 jul. 2026.

EMBRAPA. Análise qualitativa dos eventos fenológicos do açaizeiro (*Euterpe oleracea* Mart.), na Embrapa Amazônia Oriental, Belém/PA. Portal Embrapa. Disponível em: <https://www.embrapa.br/en/busca-de-publicacoes/-/publicacao/1113403/>. Acesso em: 06 jul. 2026.

EMBRAPA. Nova cultivar de açaizeiro vai manter fornecimento do fruto o ano todo. Portal Embrapa, 2019. Disponível em: <https://www.embrapa.br/en/busca-de-noticias/-/noticia/48210103/>. Acesso em: 06 jul. 2026.

FAPESPA – FUNDAÇÃO AMAZÔNIA DE AMPARO A ESTUDOS E PESQUISAS. Conjuntura da Economia do Açaí 2024. Belém: Fapespa, 2024. Disponível em: <https://www.fapespa.pa.gov.br/wp-content/uploads/2024/06/Nota-Tecnica-Conjuntura-da-Economia-do-Acai-2024.pdf>. Acesso em: 07 jul. 2026.

GARZA, M. et al. Modelling the climatic suitability of Chagas disease vectors on a global scale. *eLife*, v. 9, e52072, 2020. Disponível em: <https://elifesciences.org/articles/52072>. Acesso em: 06 jul. 2026.

GUARNERI, A. A.; LAZZARI, C.; XAVIER, A. A. P.; DIOTAIUTI, L.; LORENZO, M. G. The effect of temperature on the behaviour and development of *Triatoma brasiliensis*. *Physiological Entomology*, v. 28, p. 185-191, 2003.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Produção de Açaí (cultivo) no Pará. Explica: Produção Agropecuária. Rio de Janeiro: IBGE, [s.d.]. Disponível em: <https://www.ibge.gov.br/explica/producao-agropecuaria/acai-cultivo/pa>. Acesso em: 07 jul. 2026.

MUÑOZ-SABATER, J.; DUTRA, E.; AGUSTÍ-PANAREDA, A.; ALBERGEL, C.; ARDUINI, G.; BALSAMO, G. et al. ERA5-Land: a state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data*, v. 13, n. 9, p. 4349-4383, 2021. doi: 10.5194/essd-13-4349-2021.

NÓBREGA, A. A.; GARCIA, M. H.; TATTO, E.; OBARA, M. T.; COSTA, E.; SOBEL, J.; ARAUJO, W. N. Oral transmission of Chagas disease by consumption of açai palm fruit, Brazil. *Emerging Infectious Diseases*, v. 15, n. 4, p. 653-655, 2009.

OLIVEIRA, M. do S. P. de; NETO, J. T. de F.; PENA, R. S. Açai: técnicas de cultivo e processamento. Belém: Instituto Frutal, 2007. 104 p.

PACHECO, L. V.; SANTANA, L. S.; BARRETO, B. C.; SANTOS, E. S.; MEIRA, C. S. Transmissão oral da doença de Chagas: uma revisão de literatura. *Research, Society and Development*, v. 10, n. 2, e28710212701, 2021.

REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. You only look once: Unified, real-time object detection. In: *IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR)*, 2016. Proceedings [...]. p. 779-788.

SAPKOTA, R.; KARKEE, M. Comparing YOLOv11 and YOLOv8 for instance segmentation of occluded and non-occluded immature green fruits in complex orchard environment. *arXiv:2410.19869*, 2024. Disponível em: <https://arxiv.org/abs/2410.19869>. Acesso em: 06 jul. 2026.

ULTRALYTICS. YOLO11 Documentation. 2024. Disponível em: <https://docs.ultralytics.com>. Acesso em: 06 jul. 2026.